PROYECTO FINAL INTEGRADOR · ESPECIALIZACIÓN EN MACHINE LEARNING · UNIVERSIDAD EAN

Guía de sustentación

Producción anual y diaria de las Reservas 1P de Colombia y regalías esperadas según WTI y Brent.

Integrantes: Rafael Fajardo Moreno, Sonia Catalina Martinez Herrera y Laura Marcela Garnica Tapia · Octubre de 2026

> **Uso académico.** Datos de carácter reservado (IRR 2024), con nombres de campos y contratos anonimizados. Aplicativo: https://rafafajardo-ux.github.io/TRABAJO-FINAL/ (con términos y contraseña) · Repositorio: https://github.com/rafafajardo-ux/TRABAJO-FINAL

Guía para preparar la exposición ante el jurado. Sigue la estructura recomendada en cuatro momentos y la llena con las cifras del proyecto, siempre con su incertidumbre y con la línea base al lado. Al final, el apartado Conceptos clave explica cada métrica, los pliegues y los demás conceptos que el jurado puede preguntar.

Cuatro reglas para la presentación

UNA IDEA POR DIAPOSITIVA

Máximo 10 diapositivas, más las de anexo que se consideren. Quien lea solo los títulos debe poder reconstruir el argumento.

EMPEZAR POR LA DECISIÓN

No por el algoritmo: el jurado primero quiere saber para qué sirve.

CIFRAS CON INCERTIDUMBRE

Siempre con su margen y con la línea base al lado. Una cifra aislada no dice nada.

DECLARAR LOS LÍMITES

Decir lo que el proyecto no demuestra. Declarar un límite puntúa; esconderlo se nota.

Estructura recomendada de la exposición

MOMENTO	QUÉ CONTIENE	QUÉ DECIMOS EN ESTE PROYECTO
1. Problema y decisión	Qué se decide, quién decide, cuál es el resultado clave y cuánta incertidumbre trae.	**Decisión:** cuántos barriles y cuántas regalías presupuestar por año en el Sistema General de Regalías, y qué campos revisar antes. **Deciden:**

MOMENTO	QUÉ CONTIENE	QUÉ DECIMOS EN ESTE PROYECTO
		Ministerio de Minas y Energía, ANH y DNP; afecta a departamentos y municipios productores. **Resultado clave:** 724 mil bpd en 2026 y regalías por USD 2.368 millones a WTI o 2.599 a Brent; 535 mil bpd en 2027. **Incertidumbre:** error mediano de ±15 % por campo, WAPE de 9,6 % ± 2,0 en validación cruzada y sesgo del total país de −3,1 % en la prueba; la elección WTI o Brent mueve las regalías cerca de 10 %.
2. Datos y diseño	Procedencia, calidad, sesgo y cómo se evitó la fuga.	**Procedencia:** datos reales del IRR 2024 (corte 31-dic-2023) y producción fiscalizada 2023 a junio de 2026, anonimizados. **Calidad:** sin duplicados ni negativos; 196 celdas vacías excluidas (no se tratan como cero); 2026 es medio año, por eso se compara en barriles por día. **Sesgo:** 9 campos producen la mitad del volumen; los campos pequeños tienen más error; 70 campos sin 1P salen del pronóstico después de 2026. **Fuga:** solo variables conocidas antes del año, validación cruzada agrupada por campo, preparación dentro del pipeline y prueba 2026 usada una sola vez.
3. Modelos y evaluación	Línea base, modelos comparados, métrica según el costo del error y umbral.	**Líneas base:** Reserva 1P tal cual (25,4 % de error en la prueba) y persistencia (8,1 %). **Modelos:** árbol de decisión, Random Forest, Gradient Boosting, regresión lineal (MCO y Ridge) y red neuronal; gana Random Forest con 9,6 % en validación cruzada y 8,4 % en la prueba. **Métrica:** WAPE, porque el error cuesta en barriles, y sesgo del total país, porque un sesgo positivo promete regalías que no llegan. **Umbral:** alerta si el pronóstico no alcanza la 1P (1,00), elegido con costo 3:1; detecta el 94 % de los incumplimientos con 69 % de precisión.
4. Recomendación, límites y riesgos	Qué se recomienda, qué la invalidaría y a quién podría perjudicar.	**Recomendación:** usar el modelo para planear 12 a 24 meses, con la 1P como tope, y revisar con los operadores los campos en alerta antes de presupuestar. **Qué la invalidaría:** choques operativos o de orden público, una nueva 1P (IRR más reciente), unificaciones de campos o un sesgo del total país mayor a ±5 % en el seguimiento. **A quién podría perjudicar:** a municipios productores pequeños si el

MOMENTO	QUÉ CONTIENE	QUÉ DECIMOS EN ESTE PROYECTO
		pronóstico sobreestima (sus campos tienen 22 % de error) y a los municipios de los 70 campos sin 1P, que quedan subestimados.

Guion propuesto: 10 diapositivas

Los títulos están escritos como frases: leídos en orden, cuentan el argumento completo.

#	TÍTULO DE LA DIAPOSITIVA	MOMENTO	QUÉ MOSTRAR
1	Para presupuestar regalías se necesita un pronóstico por campo mejor que la Reserva 1P	Problema y decisión	La decisión, quién decide y a quién afecta
2	En 2026 se esperan 724 mil bpd y USD 2.368 a 2.599 millones de regalías, con ±15 % de error por campo	Problema y decisión	Resultado clave con su incertidumbre y el rango WTI–Brent
3	Los datos son reales (IRR 2024 y producción 2023-2026), anonimizados y con calidad verificada	Datos y diseño	Procedencia, diagnóstico de calidad y anonimización
4	Nueve campos producen la mitad del petróleo: los pequeños tienen más error	Datos y diseño	Sesgo por tamaño: 3 % de error en grandes frente a 22 % en pequeños
5	Cuatro barreras evitan la fuga: la prueba 2026 se usó una sola vez	Datos y diseño	Esquema de validación agrupada por campo y particiones
6	Random Forest reduce el error de la 1P de 25,4 % a 8,4 %; la persistencia queda cerca	Modelos y evaluación	Tabla de modelos con las dos líneas base al lado
7	Medimos WAPE y sesgo porque el error cuesta en barriles y en presupuesto	Modelos y evaluación	Por qué esa métrica y no otra; sesgo de −3,1 %
8	Un umbral de 1,00 detecta el 94 % de los incumplimientos de la 1P	Modelos y evaluación	Costo 3:1, sensibilidad, precisión y un ejemplo de campo en alerta
9	Recomendamos planear a 12-24 meses con el modelo y usar la 1P solo como tope	Recomendación	Recomendación y gobernanza: reentrenar cada año, revisar si el sesgo pasa de ±5 %
10	Lo que el proyecto no demuestra y a quién podría perjudicar	Límites y riesgos	Límites declarados y riesgos por territorio

Anexos sugeridos: A. Curva de aprendizaje de la red neuronal · B. Árbol de decisión · C. Segmentos de campos · D. Aplicativo (términos, contraseña, consulta) · E. Escala de regalías de la Ley 756 · F. Trazabilidad CRISP-DM · G. Declaración de uso de IA.

Qué se espera ver en la sustentación

DEFENSA TÉCNICA

Defender los modelos, las métricas y el diseño experimental: por qué ese modelo, por qué esa métrica y cómo se garantizó que la cifra es honesta.

CONTROL DEL PROYECTO

Calidad y gobernanza de los datos, trazabilidad de las fases de CRISP-DM y puente entre la decisión de negocio y el equipo técnico.

NEGOCIO Y CONSECUENCIAS

La pregunta de negocio, la decisión que se toma con la predicción, sus límites y a quiénes puede perjudicar.

Trazabilidad CRISP-DM

FASE	EVIDENCIA	DÓNDE ESTÁ
Comprensión del negocio	Decisión, métricas de éxito, alcance IRR 2024	Informe §1 · cuaderno §1 · anexo A
Comprensión de los datos	Ficha de datos, diagnóstico de calidad, anonimización	ficha_datos.md · cuaderno §2 · anexo B
Preparación	Conjunto campo-año, variables ex ante, barreras contra la fuga	Informe §3 · cuaderno §3
Modelado	Seis modelos y tres líneas base con validación cruzada agrupada	Informe §4 · cuaderno §4 · comparacion_modelos.csv
Evaluación	Prueba 2026, error por tamaño, umbral, segmentos	Informe §5 · cuaderno §5 · página Modelos
Despliegue	Aplicativo en línea con términos y contraseña, documentos, repositorio	GitHub · aplicativo · guía §11

Lo que el proyecto no demuestra

- Que el modelo supere con claridad a la persistencia en el corto plazo: en la prueba 2026 obtuvo 8,4 % frente a 8,1 %, una diferencia dentro de la variabilidad (±2,0

puntos). Su ventaja está en la validación cruzada (9,6 % frente a 11,9 %) y en que sigue el declive de la 1P.

- La precisión del pronóstico de largo plazo: solo hay tres años objetivo (2024, 2025 y medio 2026); después de 2027 manda el perfil 1P.
- La producción total esperada del país: no incluye la migración de reservas 2P y 3P ni los recursos contingentes, por eso es un piso conservador.
- Los precios futuros: desde 2028 son un supuesto constante.
- La liquidación oficial de regalías: la tasa se aproxima con la Ley 756 sobre el promedio anual y sin el descuento para crudos pesados, porque el archivo no trae la gravedad API.

Preguntas probables del jurado

▼ ¿Por qué Random Forest y no la persistencia, si en 2026 la persistencia tuvo menos error?

Porque la regla de elección, fijada antes de ver la prueba, fue la validación cruzada agrupada por campo: 9,6 % frente a 11,9 %. Un solo semestre de prueba no basta para ordenar dos métodos que difieren 0,3 puntos. Además, la persistencia no anticipa el declive de la 1P, que es lo que importa desde 2027.

▼ ¿Por qué WAPE y no el error porcentual medio o el R^2?

Porque el costo del error está en barriles y en el presupuesto: un error de 1.000 bpd pesa igual en un campo grande o pequeño. El error porcentual medio lo dominarían los campos pequeños. El R^2 en escala logarítmica se reporta solo como referencia.

▼ ¿Cómo garantizan que la cifra es honesta?

Con cuatro barreras contra la fuga: solo variables conocidas antes del año, validación cruzada agrupada por campo, preparación dentro del pipeline y prueba 2026 usada una sola vez. El cuaderno es reproducible (semilla 42 y versiones declaradas), y la anonimización no cambia ningún resultado.

▼ ¿Por qué el umbral es 1,00 y no 0,90?

Porque no detectar un incumplimiento (presupuestar regalías que no llegan) cuesta tres veces una falsa alarma (una revisión con el operador). Con ese costo, 1,00 minimizó el costo en 2025 y en 2026 detectó el 94 % frente al 84 % del umbral de 0,90.

▼ ¿A quién podría perjudicar el modelo?

A los municipios productores pequeños si el pronóstico sobreestima, porque sus campos tienen más error (22 % en los de menos de 1.000 bpd), y a los municipios de los 70 campos sin 1P, que quedan fuera del pronóstico después de 2026.

▼ ¿Cómo protegieron los datos reservados?

Los nombres de campos y contratos están anonimizados, la tabla de correspondencia no se publica, el aplicativo exige aceptar los términos y una contraseña única que se solicita por correo, y hay una declaración de uso de IA.

CONCEPTOS CLAVE

Qué significa cada métrica y por qué se usa

Este apartado complementa la guía de sustentación: explica, sin salir del documento, cada métrica, cada partición de los datos y cada concepto que aparece en el proyecto. Para cada métrica se indica qué mide, cómo se calcula, un ejemplo con las cifras del proyecto, por qué se usa aquí y cómo leerla.

A. Métricas del pronóstico de producción

WAPE · error absoluto ponderado

Qué mide. Cuántos barriles se equivoca el pronóstico por cada 100 barriles producidos, sumando todos los campos.

Cómo se calcula. `Σ |pronóstico − real| / Σ real`. Se suman los errores absolutos de todos los campos y se dividen por la producción real total.

Ejemplo. En la prueba 2026 el Random Forest tuvo 8,4 %: por cada 100 barriles reales, los errores de los campos suman unos 8. Con la Reserva 1P tal cual serían 25.

Por qué se usa. Es la métrica principal porque el costo del error está en barriles: un error de 1.000 bpd pesa lo mismo en un campo grande que en uno pequeño, y eso es lo que llega o deja de llegar a cada municipio.

Menos es mejor. 0 % sería un pronóstico perfecto.

Sesgo del total país

Qué mide. Si el pronóstico, sumado para todo el país, queda por encima o por debajo de lo real.

Cómo se calcula. `Σ pronóstico / Σ real − 1`.

Ejemplo. −3,1 % en la prueba 2026: el modelo pronosticó para el país un 3,1 % menos de lo que se produjo. Es una subestimación leve.

Por qué se usa. El presupuesto de regalías depende del total. Un sesgo positivo promete regalías que no llegan; uno negativo deja recursos sin programar. La meta fue un sesgo menor a ±5 %.

Cerca de 0 es mejor. A diferencia del WAPE, los errores de signo contrario se compensan.

MAE · error absoluto medio

Qué mide. El error promedio de un campo cualquiera, en barriles por día.

Cómo se calcula. promedio de |pronóstico − real| .

Ejemplo. 229 bpd con el Random Forest frente a 688 bpd con la 1P tal cual.

Por qué se usa. Traduce el error a una cifra concreta por campo, fácil de explicar a un operador o a un municipio.

Menos es mejor. Está en la misma unidad que la producción.

RMSE · raíz del error cuadrático medio

Qué mide. Como el MAE, pero castiga mucho más los errores grandes, porque los eleva al cuadrado.

Cómo se calcula. √ promedio de (pronóstico − real)² .

Ejemplo. 608 bpd con el Random Forest frente a 1.667 bpd con la 1P. Que el RMSE sea mucho mayor que el MAE indica que hay pocos campos con errores grandes.

Por qué se usa. Muestra si el modelo comete errores grandes ocasionales, que son los más costosos en campos grandes.

Menos es mejor. Siempre es mayor o igual que el MAE.

R^2 en escala logarítmica

Qué mide. Qué proporción de las diferencias de producción entre campos explica el modelo, medida sobre el logaritmo de los barriles por día.

Cómo se calcula. 1 − (suma de errores² / suma de desviaciones² respecto a la media) , sobre log(1 + bpd).

Ejemplo. 0,926 con el Random Forest frente a 0,706 con la 1P.

Por qué se usa. Solo como referencia estadística. En escala logarítmica todos los campos pesan parecido, así que no refleja el costo en barriles; por eso no se usa para decidir.

Más es mejor; 1 sería perfecto.

Porcentaje de campos con error mayor a 20 %

Qué mide. Cuántos campos quedarían mal programados si se usara el pronóstico.

Cómo se calcula. Número de campos con |pronóstico − real| / real > 0,20, dividido por el total de campos.

Ejemplo. 42 % con el Random Forest frente a 68 % con la 1P. Son sobre todo campos pequeños.

Por qué se usa. Complementa el WAPE: muestra cuántos territorios tendrían un pronóstico poco fiable aunque pesen poco en barriles.

Menos es mejor.

Desviación entre pliegues (±)

Qué mide. Cuánto cambia el error de un pliegue a otro de la validación cruzada.

Cómo se calcula. Desviación estándar de los cinco WAPE, uno por pliegue.

Ejemplo. 9,6 % ± 2,0: según qué campos se dejen fuera, el error varía cerca de 2 puntos.

Por qué se usa. Da la incertidumbre de la cifra. Por eso la diferencia de 0,3 puntos con la persistencia en la prueba 2026 no es concluyente.

Menos es mejor: indica un modelo estable.

Error mediano por campo (±15 %)

Qué mide. El error porcentual de un campo típico: la mitad de los campos tiene un error menor y la otra mitad, mayor.

Cómo se calcula. Mediana de |pronóstico − real| / real en la validación 2025.

Ejemplo. ±15 %: para un campo cualquiera, el pronóstico suele quedar dentro de un 15 % del valor real.

Por qué se usa. Es la banda de incertidumbre que muestra el aplicativo al consultar un campo o un año futuro.

Menos es mejor. La mediana no se deja arrastrar por unos pocos campos con errores enormes.

Error cuadrático medio ponderado (curva de aprendizaje)

Qué mide. El error de la red neuronal sobre el cambio logarítmico, en cada época del entrenamiento.

Cómo se calcula. Promedio de (cambio real − cambio pronosticado)², ponderado por la raíz del tamaño del campo.

Ejemplo. En la época 21 la validación llega a su mínimo (0,128); en la época 400 el entrenamiento baja a 0,006 y la prueba sube a 0,206.

Por qué se usa. Es lo que la red minimiza al aprender, y compararlo entre entrenamiento y validación muestra el sobreajuste.

Menos es mejor; importa la separación entre curvas.

B. Métricas de la alerta de bajo cumplimiento

La alerta es una clasificación: para cada campo se predice si va a **incumplir** (producir menos del 90 % de su Reserva 1P) y se compara con lo que pasó. Todas estas métricas salen de la **matriz de confusión**.

PRUEBA 2026 (257 CAMPOS)	INCUMPLIÓ DE VERDAD	CUMPLIÓ DE VERDAD
Con alerta	97 · verdaderos positivos (VP)	43 · falsas alarmas (FP)
Sin alerta	6 · incumplimientos no detectados (FN)	111 · verdaderos negativos (VN)

Cómo leer VP, FP, FN y VN

Cada sigla tiene dos partes. La segunda dice **qué predijo la alerta**: **positivo** = hubo alerta (se predijo que el campo incumple); **negativo** = no hubo alerta. La primera dice **si acertó**: **verdadero** = la predicción fue correcta; **falso** = se equivocó.

VP · verdaderos positivos (97). Hubo alerta y el campo sí incumplió. Son los aciertos que importan.

FP · falsos positivos o falsas alarmas (43). Hubo alerta, pero el campo cumplió. Error leve: se revisó un campo que no lo necesitaba.

FN · falsos negativos o incumplimientos no detectados (6). No hubo alerta, pero el campo incumplió. Es el error grave: nadie lo revisó y sus regalías se presupuestaron completas.

VN · verdaderos negativos (111). No hubo alerta y el campo cumplió.

Los cuatro suman los 257 campos de la prueba. Los que de verdad incumplieron son VP + FN = 103; las alertas emitidas son VP + FP = 140.

Cumplimiento pronosticado

Qué mide. Qué fracción de su Reserva 1P se espera que produzca un campo.

Cómo se calcula. `producción pronosticada / Reserva 1P del año`.

Ejemplo. Campo_085 en 2027: 18,0 / 18,7 millones de barriles = 0,97.

Por qué se usa. Es el puntaje con el que se decide la alerta: si es menor que el umbral, se alerta.

Sensibilidad (o exhaustividad)

Qué mide. De los campos que de verdad incumplieron, cuántos detectó la alerta.

Cómo se calcula. `VP / (VP + FN)`. VP son los incumplimientos que la alerta sí detectó (97) y FN los que se le escaparon (6); juntos, VP + FN, son todos los campos que de verdad incumplieron (103). Entonces 97 / 103 = 0,94: se detectaron 94 de cada 100 incumplimientos y se escaparon 6 campos.

Por qué se usa. Es la métrica que más importa aquí: un incumplimiento no detectado significa presupuestar regalías que no van a llegar.

Más es mejor; 1 = no se escapa ningún incumplimiento.

Precisión

Qué mide. De las alertas emitidas, cuántas fueron incumplimientos reales.

Cómo se calcula. `VP / (VP + FP)`. VP son las alertas que acertaron (97) y FP las falsas alarmas (43); juntas, VP + FP, son todas las alertas emitidas (140). Entonces 97 / 140 = 0,69.

Por qué se usa. Mide el costo de revisar: 31 de cada 100 alertas son falsas alarmas, que solo cuestan una conversación con el operador.

Más es mejor. Suele bajar cuando la sensibilidad sube.

AUC · área bajo la curva ROC

Qué mide. Qué tan bien ordena el puntaje a los campos, sin fijar todavía un umbral: la probabilidad de que un campo que incumple tenga peor puntaje que uno que cumple.

Cómo se calcula. Se prueban todos los umbrales posibles y se mide el área bajo la curva de sensibilidad frente a tasa de falsas alarmas.

Ejemplo. 0,93 en la prueba 2026.

Por qué se usa. Separa dos preguntas: si el puntaje sirve (AUC) y dónde poner el corte (umbral).

0,5 = azar; 1 = separación perfecta.

Umbral y costo medio

Qué es. El valor de cumplimiento por debajo del cual se emite alerta. Se eligió 1,00: alertar todo campo cuyo pronóstico no alcance su 1P.

Cómo se eligió. Se probaron umbrales de 0,70 a 1,20 en la validación 2025 y se escogió el de menor `costo medio = (3 × FN + 1 × FP) / campos`, donde FN es el número de incumplimientos no detectados (campos que incumplieron sin alerta) y FP el número de falsas alarmas (campos con alerta que sí cumplieron).

Por qué 3 y 1. Son pesos que dicen cuánto cuesta cada error comparado con el otro. Una falsa alarma vale 1: solo obliga a revisar el campo con el operador antes de presupuestar. Un incumplimiento no detectado vale 3: se presupuestan regalías que no llegan, y los departamentos y municipios comprometen proyectos que después hay que recortar o aplazar. La proporción 3 a 1 es un supuesto del equipo, basado en el criterio de quien planea las regalías, no un valor estimado con los datos. Importa la proporción y no los números: con 6 y 2 se elegiría el mismo umbral. Si el FN pesara más, el umbral tendería a subir y habría más alertas; si pesara menos, a bajar.

Ejemplo. Costo medio en 2026 con el umbral 1,00: (3 × 6 + 1 × 43) / 257 = 61 / 257 = 0,237. Con el umbral de 0,90 sería 0,257: habría menos falsas alarmas, pero más incumplimientos no detectados (detecta el 84 % en lugar del 94 %), y cada uno pesa el triple.

Por qué se usa. El umbral traduce el costo del negocio en una regla: se acepta revisar algunos campos de más para no dejar pasar incumplimientos.

C. Métricas de los segmentos

Coeficiente de silueta

Qué mide. Qué tan bien separados están los grupos: si cada campo está más cerca de los de su segmento que de los del segmento vecino.

Cómo se calcula. Para cada campo, `(b − a) / máx(a, b)`, donde a es la distancia media a su propio grupo y b la distancia media al grupo más cercano. Se promedia sobre todos los campos.

Ejemplo. Se probaron k = 2 a k = 7. El mejor fue k = 5, con 0,33; k = 2 dio 0,30 y k = 7, 0,28.

Por qué se usa. Para elegir cuántos segmentos formar sin mirar ninguna etiqueta.

De −1 a 1. Cerca de 0,3 indica grupos razonables con fronteras difusas, algo esperable en datos reales.

Varianza explicada por un componente

Qué mide. Qué parte de las diferencias entre campos resume cada componente principal.

Ejemplo. El componente 1 resume el 35 % y el componente 2, el 26 %: entre los dos, el 61 % de lo que distingue a los campos.

Por qué se usa. Indica cuánto se pierde al dibujar seis variables en un plano de dos ejes.

D. Validación: pliegues y particiones

Qué es un pliegue

Un **pliegue** es una de las cinco partes en que se dividen los datos de 2024-2025 para validar. En cada ronda, un pliegue se aparta para medir el error y los otros cuatro se usan para entrenar. Se hacen cinco rondas, de modo que cada pliegue sirve una vez como validación.

En este proyecto. Las 586 filas (campo × año) se reparten en cinco pliegues de unas 117 filas. El error final es el promedio de los cinco errores, con su desviación.

Validación cruzada agrupada por campo

Los pliegues no se forman al azar por fila, sino **por campo**: las filas 2024 y 2025 de un mismo campo van siempre juntas en el mismo pliegue.

Por qué. Si un campo estuviera en entrenamiento (2024) y en validación (2025), el modelo lo «reconocería» y el error parecería menor de lo que será con campos que no ha visto. Agrupar por campo evita esa fuga.

Cómo funciona cada ronda

1. Ronda 1: entrena con los pliegues 2, 3, 4 y 5; mide el error en el pliegue 1.
2. Ronda 2: entrena con 1, 3, 4 y 5; mide en el 2.
3. Rondas 3, 4 y 5: igual, rotando el pliegue apartado.
4. Se promedian los cinco errores: 9,6 % ± 2,0 para el Random Forest.
5. Esto se repite para cada combinación de hiperparámetros de cada modelo.

Validación temporal

Se entrena solo con 2024 y se evalúa en 2025: se simula pronosticar un año que todavía no ha ocurrido.

Por qué. Comprueba que el modelo funciona hacia adelante en el tiempo y no solo con campos nuevos. También se usó para elegir el umbral.

Conjunto de prueba (2026)

La producción de enero a junio de 2026 se guardó sin tocar durante todo el desarrollo. Se usó **una sola vez**, al final, con el modelo ya elegido.

Por qué. Si se usara para elegir el modelo o el umbral, la cifra quedaría optimista. Una prueba usada una sola vez es la cifra honesta.

Fuga de información

Ocurre cuando el modelo usa, sin querer, información que no se conocería en el momento de pronosticar. Produce errores falsamente bajos que no se repiten en la realidad.

Cómo se evitó. Solo variables conocidas antes del año, validación agrupada por campo, preparación dentro del pipeline y prueba 2026 usada una vez.

Pipeline

La cadena de pasos que va de los datos al pronóstico: codificar categorías, escalar variables y aplicar el modelo. Se ajusta completa con los datos de entrenamiento de cada pliegue.

Por qué. Si el escalado se calculara con todos los datos, el pliegue de validación «filtraría» información al entrenamiento.

Hiperparámetros y búsqueda en malla

Los **hiperparámetros** son ajustes que se fijan antes de entrenar: la profundidad de un árbol, el número de árboles, la regularización α o el tamaño de las capas de una red.

La **búsqueda en malla** prueba todas las combinaciones de una lista y se queda con la de menor WAPE en la validación cruzada. Ejemplo: el Random Forest eligió profundidad 8 y mínimo 5 casos por hoja.

E. Modelos y entrenamiento

Línea base
Método simple contra el que se compara el modelo. Si el modelo no lo supera, no aporta. Aquí hay tres: la Reserva 1P tal cual, la persistencia y la persistencia ajustada por la pendiente de la 1P.

Persistencia
Pronosticar que un campo producirá lo mismo que el año anterior. Es la línea base técnica más exigente porque la producción cambia poco de un año a otro.

Cambio logarítmico (objetivo del modelo)
log(bpd del año / bpd del año anterior). 0 = se mantiene; −0,10 ≈ cae 10 %; +0,10 ≈ sube 10 %. Se predice el cambio y no el nivel porque así el modelo parte de la persistencia y aprende cuándo se aparta de ella.

Factor de smearing (retransformación)
Al volver de logaritmos a barriles, el promedio queda sesgado hacia abajo. El factor de Duan, calculado con los residuos de entrenamiento, corrige ese sesgo.

Ponderación por tamaño
Cada campo pesa en el entrenamiento según la raíz de su producción previa: los grandes pesan más, sin anular a los pequeños.

Árbol de decisión
Divide los campos con preguntas sí/no sobre sus variables y asigna a cada hoja el cambio promedio de sus campos. Es el modelo más fácil de explicar.

Random Forest
Promedia 500 árboles, cada uno entrenado con una muestra distinta de los datos. El promedio reduce el error de un árbol individual. Es el modelo final.

Gradient Boosting
Construye árboles pequeños en secuencia; cada uno corrige el error que dejaron los anteriores.

Regresión lineal (MCO)
Suma el efecto de cada variable con un peso fijo (coeficiente), elegido para minimizar el error cuadrático.

Regresión Ridge
Regresión lineal que penaliza los coeficientes grandes (parámetro α) para evitar el sobreajuste. Con α = 30 dio casi lo mismo que la lineal simple.

Red neuronal (perceptrón multicapa)
Capas de «neuronas» que combinan las variables de forma no lineal. Aquí, dos capas de 64 y 32 neuronas. Necesita muchos datos para generalizar.

Época
Una pasada completa de la red neuronal por todos los datos de entrenamiento. La red se entrena durante muchas épocas.

Sobreajuste

Cuando el modelo memoriza los datos de entrenamiento en lugar de aprender patrones generales: su error de entrenamiento sigue bajando mientras el de validación sube.

Importancia por permutación

Cuánto empeora el modelo si se desordenan al azar los valores de una variable. Si empeora mucho, la variable es importante. La más importante fue la producción del año anterior.

Componentes principales

Combinaciones de las variables originales que resumen la mayor variación posible. Permiten dibujar en dos ejes campos descritos por seis variables.

Parada temprana

Detener el entrenamiento en la época en que el error de validación deja de mejorar, para evitar el sobreajuste.

K-medias

Agrupa los campos en k grupos de modo que cada campo quede cerca del centro de su grupo. Es aprendizaje no supervisado: no usa ninguna respuesta conocida.

CRISP-DM

Método estándar de proyectos de analítica en seis fases: comprensión del negocio, comprensión de los datos, preparación, modelado, evaluación y despliegue.

F. Conceptos del negocio petrolero

Reservas 1P (probadas)

Volumen que se espera producir con alta certeza. El perfil anual de cada campo es el «dato óptimo proyectado» y el tope del pronóstico desde 2027.

Recursos contingentes

Volúmenes descubiertos que todavía no cumplen las condiciones para ser reservas. No se contemplan.

bpd

Barriles por día: producción anual dividida por los días del año (366 en 2024; 181 en el primer semestre de 2026).

Reservas 2P y 3P (probables y posibles)

Volúmenes adicionales con menor certeza. Aquí solo entran como variables; su migración a probadas no se modela.

IRR 2024

Informe de Recursos y Reservas presentado en 2024, con corte al 31 de diciembre de 2023. Es la fuente del perfil 1P, 2P y 3P.

WTI y Brent

Precios internacionales de referencia del petróleo, en dólares por barril. El Brent suele ser algunos dólares más caro; por eso las regalías a Brent son cerca de 10 % mayores.

Tasa de regalías (Ley 756 de 2002)

Porcentaje de la producción que corresponde al Estado: 8 % hasta 5.000 bpd y sube con la producción del campo hasta 25 % por encima de 600.000 bpd.

Pronosticado

Reservas 1P del año × precio promedio del año (WTI o Brent). Es el valor bruto de la producción 1P.

Regalías proyectadas y por producción

Las proyectadas se calculan sobre la Reserva 1P del año; las de producción, sobre la producción pronosticada. Ambas se expresan en barriles y en dólares (barriles × precio).

Tope 1P

Regla del ejercicio: desde 2027 la producción pronosticada de un campo nunca supera su Reserva 1P del año.

Guía de sustentación del PFI · Uso exclusivamente académico (Especialización en Machine Learning, Universidad EAN, 2026).